UNIVERSITAS NEGERI SURABAYA FAKULTAS MATEMATIKA
DAN ILMU PENGETAHUAN ALAM PRODI S1
SAINS DATA

Kampus 1 Unesa
Gedung E2 Ketintang
Surabaya 60231
datascience@unesa.ac.id
https://datascience.fmipa.unesa.ac.id

Nama : Mutiara Nur Fadhilatun Ni'mah

Kelas : 2024B

NIM : 24031554116

Dosen Pengampu : Dr.Atik WIntarti, M.Kom.

JAWABAN SOAL UTS GRAF SAINS DATA

Pertanyaan Pendahuluan (*Checkpoint*)

1. Apa nama database yang digunakan pada tutorial ini?
2. Sebutkan akses lain (seperti sintaks DDL/DML CYPHER) yang dapat digunakan mengakses database lain dalam 1 instance!
3. Apa jenis graf pertemanan yang telah dibuat di sini?

CYPHER Total Reset

Jalankan perintah berikut untuk melakukan *truncate* pada konten database.

```
MATCH (n) DETACH DELETE n;
```

* Hati-hati dalam menggunakan perintah ini pada *shared database*.

Pertanyaan Pendahuluan (Checkpoint)

1. **Apa nama database yang digunakan pada tutorial ini?**

   Database yang digunakan bernama neo4j (terlihat dari parameter database_="neo4j" di dalam fungsi execute_query).

2. **Sebutkan akses lain (seperti sintaks DDL/DML CYPHER) yang dapat digunakan mengakses database lain dalam 1 instance!**
   - Klausa USE pada Cypher: Digunakan di dalam query untuk menentukan sasaran database secara spesifik, contohnya: USE myotherdb MATCH (n) RETURN n;.
   - Multi-database Driver Session: Membuka session khusus ke database spesifik menggunakan sintaks driver session(database="nama_database").
   - Akses Sistem (System Database): Menggunakan USE system untuk menjalankan perintah administrasi DDL/DML seperti SHOW DATABASES, CREATE DATABASE <name>, atau DROP DATABASE <name>.
3. **Apa jenis graf pertemanan yang telah dibuat di sini?**

   Jenis graf yang dibuat adalah Directed Graph (Graf Berarah) karena hubungan ditentukan secara spesifik berarah tunggal dari satu node ke node lain melalui relasi (a)-[:KNOWS]->(friend). Artinya, "Arthur mengenal Guinevere", namun tidak otomatis berarti "Guinevere mengenal Arthur" kecuali dibuatkan relasi sebaliknya.

UNIVERSITAS NEGERI SURABAYA FAKULTAS MATEMATIKA
DAN ILMU PENGETAHUAN ALAM PRODI S1
SAINS DATA

Kampus 1 Unesa
Gedung E2 Ketintang
Surabaya 60231
datascience@unesa.ac.id
https://datascience.fmipa.unesa.ac.id

1. Soal UTS

Petunjuk Khusus

1. Deadline: Sesuai LMS SiDia.
2. Modifikasi kode sumber sesuai dengan kebutuhan Anda.
3. Unggah pekerjaan Anda (dokumentasi notebook ipynb dan penjelasan, serta dataset) pada akun Github Anda, dan tuliskan URL github Anda pada LMS SiDia .
4. Sesi kelas pada jadwal masing-masing akan ada pertanyaan secara acak.

1.1 Wrangling dan EDA (Maks. skor: 45)

1. **Tentukan 2 periode waktu sebagai filter dari data interaksi. Kombinasi periode yang dipilih tiap mahasiswa tidak boleh sama!**
   Saya menggunakan kombinasi periode sebagai berikut:
   - Fold Training (P1): 03 Mei 2015 00:00:00 UTC – 17 Mei 2015 23:59:59 UTC
   - Fold Testing (P2): 01 Agustus 2015 00:00:00 UTC – 15 Agustus 2015 23:59:59 UTC
2. **Terapkan proses filter ini pada timestamp pada proses persiapan data, lalu simpan pada sebuah file .csv!** File CSV saya upload di github..
3. **Lakukan query untuk mendapatkan komposisi dari *subgraph* yang dibuat. Uraikan jenis simpul dan jumlah masing-masing simpul dengan Python API! Jelaskan CYPHER SQL yang digunakan!**
   Berikut hasil query yang telah dijalankan untuk mendapatkan komposisi kedua *subgraph:*

Komposisi Subgraph P1 (TRAINING):	
Jenis Simpul	**Jumlah SImpul**
Visitor (User)	155.916
Item	78.171
Total sisi / Interaksi (Edge)	296.319
Komposisi Subgraph P2 (TESTING):	
Jenis Simpul	**Jumlah SImpul**
Visitor (User)	153.836
Item	76.078
Total sisi / Interaksi (Edge)	265.509

Kampus 1 Unesa
Gedung E2 Ketintang
Surabaya 60231
datascience@unesa.ac.id
https://datascience.fmipa.unesa.ac.id

CHYPHER SQL yang saya gunakan untuk mendapatkan komposisi dari 2 subgraph tersebut sebagai berikut:

```
MATCH (v:Visitor)-[r]->(i:Item)
WHERE r.timestamp >= $start AND r.timestamp <= $end
RETURN count(DISTINCT v) AS total_visitor,
    count(DISTINCT i) AS total_item,
    count(r) AS total_relasi
```

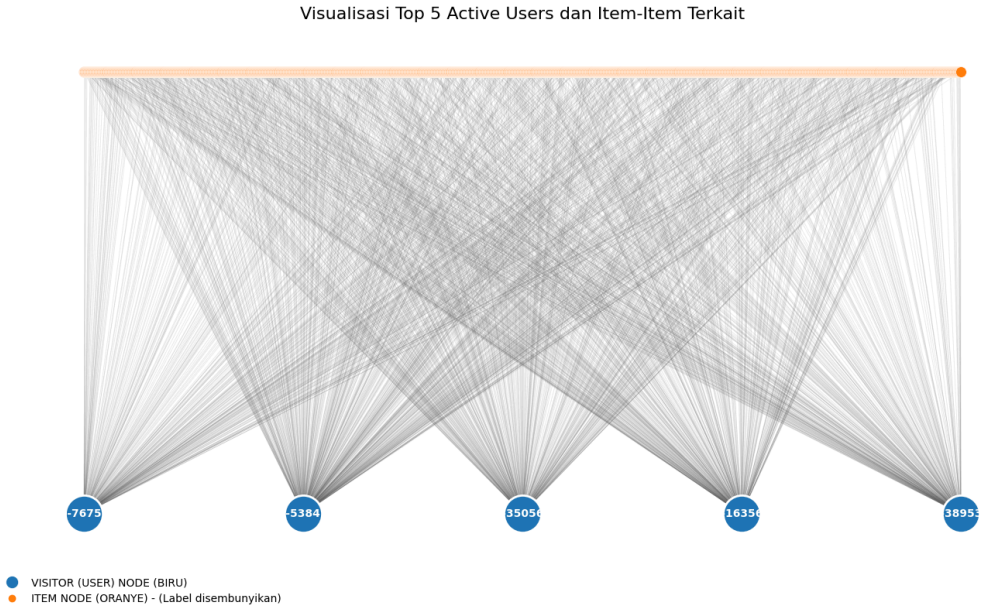
- MATCH (v:Visitor)-[r]->(i:Item): untuk memetakan struktur graf bipartite, yaitu menemukan seluruh entitas pengunjung (Visitor) yang terhubung langsung melalui relasi interaksi (VIEWED, ADDED_TO_CART, atau BOUGHT) ke produk (Item).
- WHERE r.timestamp >= $start AND r.timestamp <= end: menerapkan filter temporal pada properti timestamp relasi agar subgraph yang dihitung hanya berada di dalam rentang waktu periode terkait (P1 atau P2)
- count(DISTINCT v) & count(DISTINCT i): untuk menghitung jumlah simpul unik untuk Visitor dan Item agar node yang melakukan/menerima interaksi berulang tidak terhitung ganda.
- count(r): untuk menghitung total seluruh transaksi/interaksi yang terjadi antara Visitor dan Item pada periode tersebut.

4. Lakukan Vector Space Modelling (VSM) terhadap simpul yang diasumsikan sebagai User. Uraikan bagaimana karakteristiknya (dimensi, shape, plot networkx, dst.)!

Dari dilakukannya Vector Space Modelling (VSM) diperoleh hasil sebagai berikut:

VSM USER (VISITOR)

- Shape Matriks (Dimensi) : (155916, 78171) (Jumlah User x Jumlah Item)
- Jumlah User (Baris) : 155,916
- Dimensi Vektor (Kolom) : 78,171



Gambar 1. Visualisasi Top 5 User dan Item-item terkait

Kampus 1 Unesa
Gedung E2 Ketintang
Surabaya 60231
datascience@unesa.ac.id
https://datascience.fmipa.unesa.ac.id

Berdasarkan hasil diatas, karakteristik VSM User dapat diuraikan sebagai berikut:

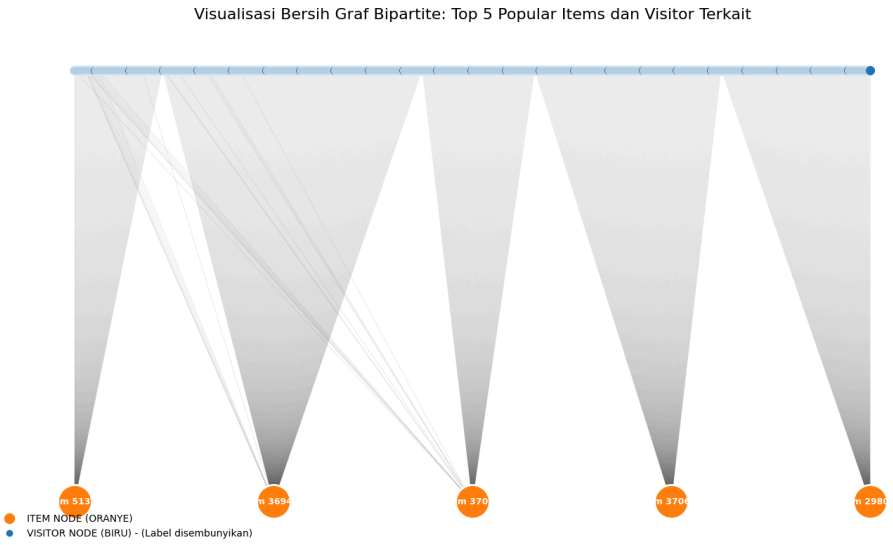
a. Shape Matriks & Dimensi:Shape Matriks: (155916, 78171)
b. Jumlah User / Baris (N): 155.916 simpul Visitor
c. Dimensi Vektor / Kolom (M): 78.171 dimensi Item
d. Representasi Vektor: Setiap User u_i dinyatakan sebagai vektor V(u_i) = [$w_{i,1}$, $w_{i,2}$,...., $w_{i,78171}$], di mana $w_{i,j}$ bernilai 1 jika terjadi interaksi di P1 dan 0 jika tidak ada.
e. Tingkat Kepadatan Matriks (Sparsity): Matriks VSM ini tergolong sangat sparse (jarang terisi). Dengan total sel sebanyak 155.916 x 78.171 ≈ 12,18 Miliar sel, hanya 296.319 sel yang terisi angka > 0 (berdasarkan total edge P1). Tingkat kerapatan matriks (density) hanya sebesar approx 0,0024%, artinya perlu menggunakan format matriks terkompresi seperti csr_matrix dari library scipy.sparse untuk efisiensi RAM.

5. **Lakukan VSM terhadap simpul yang diasumsikan sebagai Item. Uraikan bagaimana karakteristiknya (dimensi, shape, plot networkx, dst.)!**

Dari dilakukannya Vector Space Modelling (VSM) terhadap simpul yang diasumsikan sebagai Item diperoleh hasil sebagai berikut:

VSM ITEM

- Shape Matriks (Dimensi) : (78171, 155916) (Jumlah User x Jumlah Item)
- Jumlah Item (Baris) : 78.171
- Dimensi Vektor (Kolom) : 155.916
- Total Elemen Terisi : 231.267 interaksi



Gambar 2. Visualisasi Top 5 Active User dan item-item terkait

Berdasarkan hasil diatas, karakteristik dari VSM Item adalah sebagai berikut:

a. Shape Matriks & Dimensi:Shape Matriks: (78171, 155916) (Jumlah Item × Jumlah User)
b. Jumlah Item / Baris (M): 78.171 simpul Item
c. Dimensi Vektor / Kolom (N): 155.916 dimensi Visitor (User)
d. Total Elemen Terisi: 231.267 interaksi

Kampus 1 Unesa
Gedung E2 Ketintang
Surabaya 60231
datascience@unesa.ac.id
https://datascience.fmipa.unesa.ac.id

e. Representasi Vektor: Setiap produk i_k dinyatakan sebagai vektor V(i_k) = [$w_{k,1}$, $w_{k,2}$,….., $w_{k,155916}$], di mana $w_{k,j}$ merepresentasikan adanya akses/transaksi dari visitor j.

f. Sparsity & Efisiensi Komputasi:Dengan total kapasitas matriks sebesar 78.171 x 155.916 ≈ 12,18 Miliar sel, hanya 231.267 elemen yang bernilai tidak nol (> 0). Matriks ini memiliki tingkat sparsity yang sangat tinggi (≈ 0,0019%). Penggunaan struktur data Compressed Sparse Row (csr_matrix) memungkinkan komputasi Cosine Similarity antar-item berjalan secara cepat dan hemat memori.

6. Berdasarkan eksplorasi no. 4 dan 5, uraikan proyeksi manakah yang lebih baik (efektif/efisien)!

Berdasarkan eksplorasi VSM User dan VSM Item, proyeksi yang jauh lebih efektif dan efisien untuk diterapkan pada dataset e-commerce ini adalah Proyeksi Item-based Collaborative Filtering (VSM Item). Karena ada beberapa perbandingan yang membuktikan bahwa VSM item lebih efektif daripada VSM User, antara lain:

- pada platform e-commerce, jumlah pengunjung (visitors) tumbuh jauh lebih cepat dan dinamis dibandingkan katalog produk. Menghitung kemiripan berbasis Item 78.171 x 78.171 jauh lebih efisien untuk disimpan di database Neo4j dibanding menghitung kemiripan berbasis User (155.916 x 155.916), yang membutuhkan ruang matriks 4 kali lebih besar.
- Skor similarity antar-item dapat dihitung secara offline/batch (misal sekali sehari), sedangkan profil User berubah setiap detik saat mereka mengeksplorasi barang baru.
- Vektor User sangat sparse dan tidak memiliki cukup riwayat untuk dicari "kembarannya" (User-KNN). Sebaliknya, produk-produk populer dikunjungi oleh ribuan pengguna berbeda, sehingga vektor Item memiliki sinyal interaksi yang jauh lebih kaya dan stabil untuk dihitung Cosine Similarity-nya.
- VSM item menawarkan skalabilitas tinggi, latensi query Neo4j yang lebih cepat, serta mengatasi masalah sparsity pengguna anonim dengan memanfaatkan histori kolektif dari katalog produk

7. Berdasarkan analisis no. 6, lakukan perhitungan similarity pada hasil graf yg terproyeksi dengan menggunakan Python

a. Tuliskan CYPHER SQL untuk mendapatkan 5 records dengan similarity tertinggi (Anda tentukan sendiri record acuannya)!

```
MATCH (i1:Item {itemid: 369447})-[s:SIMILAR]->(i2:Item)
RETURN i1.itemid AS item_acuan,
       i2.itemid AS item_serupa,
       s.score AS similarity_score
ORDER BY s.score
DESC LIMIT 5
```

b. Tuliskan kembali nilai similarity-similarity tersebut pada graf yang telah ada! Perlihatkan hasil query-nya!

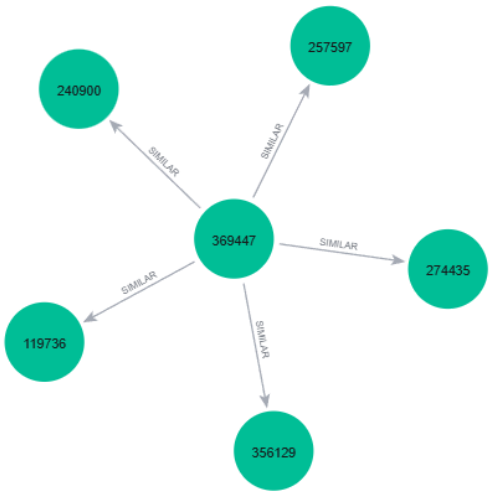
Untuk menuliskan kembali nilai-nilai similarity tersebut, saya menggunakan query sebagai berikut:

```
UNWIND $data AS row
MATCH (i1:Item {itemid: row.item1})
MATCH (i2:Item {itemid: row.item2})
MERGE (i1)-[s:SIMILAR]->(i2)
SET s.score = row.score
RETURN count(s) AS total_relasi_terbuat
```

Kampus 1 Unesa
Gedung E2 Ketintang
Surabaya 60231
datascience@unesa.ac.id
https://datascience.fmipa.unesa.ac.id

Berikut Hasil query nya:

	item_acuan	item_serupa	similarity_score
1	369447	356129	0.568435051046646
2	369447	274435	0.5185666982327823
3	369447	257597	0.31414106967600386
4	369447	240900	0.16877841637537858
5	369447	119736	0.16130490859224517



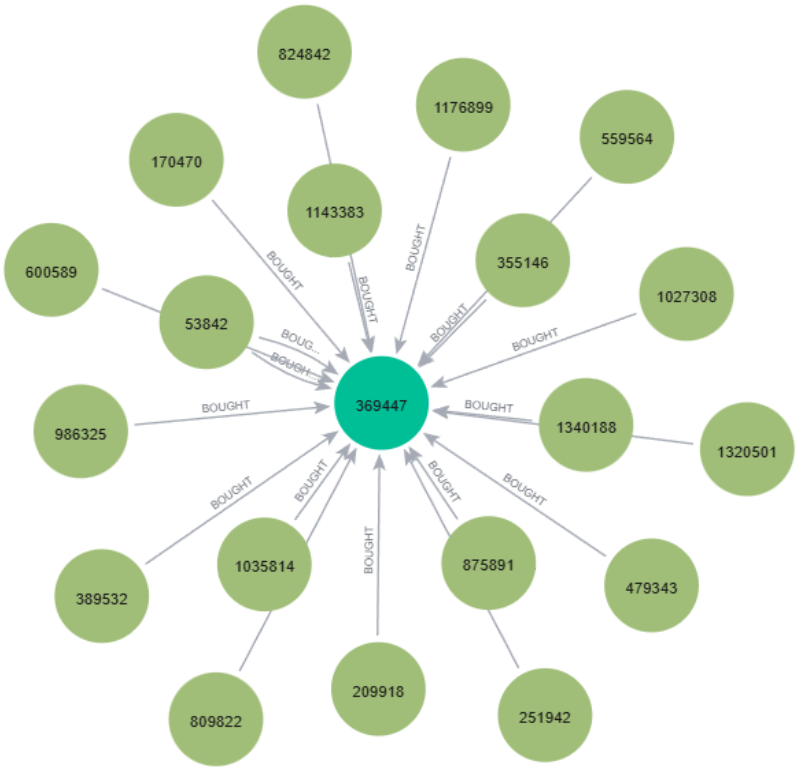
Gambar 3. Hasil Query menampilkan Top 5 Similarity

Kampus 1 Unesa
Gedung E2 Ketintang
Surabaya 60231
datascience@unesa.ac.id
https://datascience.fmipa.unesa.ac.id

8. Tuliskan CYPHER SQL dan tunjukkan hasil graf-nya untuk memperlihatkan kondisi: sebelum dan sesudah perhitungan similarity!

- Sebelum perhitungan similarity (studi kasus item 369447)

```
MATCH (v:Visitor)-[r:VIEWED|ADDED_TO_CART|BOUGHT]->(i:Item {itemid: 369447})
RETURN v, r, i
LIMIT 20;
```



Gambar 4. Visualisasi Graf Sebelum dilakukan Perhitungan Similarity

Query ini mengekstrak interaksi pengguna terhadap Item target 369447 sebelum algoritma VSM dijalankan. Pada tahap ini, Item 369447 hanya terhubung ke simpul-simpul Visitor (biru) dan tidak memiliki relasi horizontal ke produk lain.

- Setelah perhitungan similarity (studi kasus item 369447)

```
MATCH (i1:Item {itemid: 369447})-[s:SIMILAR]->(i2:Item)
OPTIONAL MATCH (v:Visitor)-[r]->(i1)
RETURN i1, s, i2, v, r
LIMIT 20;
```



Gambar 5. Visualisasi Graf Setelah dilakukan Perhitungan Similarity

Query ini menampilkan struktur graf Item 369447 setelah matriks Cosine Similarity disimpan ke Neo4j. Terlihat adanya pembentukan relasi horizontal baru :SIMILAR yang menghubungkan Item 369447 secara langsung ke produk-produk lain (i2) beserta nilai skor kemiripannya (score: 0.08354926311723322).

1.2 Analytics (Maks. skor: 55)

1. Pilih seorang *user* secara acak (tentukan proses acak-nya, dan harus bisa direproduksi), lalu
   (a) tuliskan skrip Python dalam merekomendasikan KNN-nya!
   Skrip Python ada di file ipynb atau bisa diakses melalui link GitHub.
   Berikut hasil rekomendasi KNN (K=5) dengan target user acak terpilih (user_id **763141**):

Recommended Item	Similarity Score
320130	0.136635
215596	0.106887
463617	0.088307
369447	0.088159
387373	0.086872

Kampus 1 Unesa
Gedung E2 Ketintang
Surabaya 60231
datascience@unesa.ac.id
https://datascience.fmipa.unesa.ac.id

(b) berikan 3 item yang diiklankan untuk k = 5 pada penentuan KNN nya!

3 Item yang Diiklankan untuk Target User 763141:

1. Item ID: 320130
2. Item ID: 215596
3. Item ID: 463617

Hasil eksperimen pada target user **763141** menunjukkan bahwa sistem berhasil merekomendasikan Top-5 item berbasis graf Neo4j dengan skor kemiripan tertinggi pada item 320130 (0.1366), serta memilih 3 item teratas (320130, 215596, dan 463617) untuk diiklankan.

2. Berdasarkan hasil rekomendasi Anda no. 1b Analytics, hitunglah:

(a) Hit@5

(b) NDCG@5

Berdasarkan hasil rekomendasi pada no 1b, dilakukan perhitungan Hit@5 dan NDCG@5 untuk evaluasi terhadap data aktual periode P2 (Testing) yang menghasilkan skor Hit@5 sebesar 0.0 dan NDCG@5 sebesar 0.0000 karena tidak ada satupun item dari 9 item ground truth yang dikunjungi pengguna pada periode P2 beririsan dengan item hasil rekomendasi model. Nilai zero-score ini biasa terjadi pada dataset *e-commerce* yang sangat renggang (*highly sparse*) akibat adanya pergeseran minat atau pola perilaku pengguna (*user preference drift*) antar-periode waktu, tetapi struktur metrik dan algoritma Item-based KNN berbasis graf tetap valid secara metodologis.

TAUTAN

Link GitHub: https://github.com/meutia31/UTS-GSD-Graph-Recomendation-System